

# Машинное обучение

## Лекция 1:

## Введение в МО

# Содержание

1. Общая информация о курсе
2. Введение в машинное обучение
3. Обозначения и словарь в МО
4. Виды проблем в МО
5. k Nearest Neighbours
6. Метод максимального правдоподобия
7. Наивный Байесовский классификатор

# Общая информация о курсе

Пункт 1/7

# Содержание курса

1. Классическое машинное обучение
2. Введение в глубокое обучение
3. Доменные области
  - a. Computer Vision
  - b. Natural Language Processing
4. Финальное домашнее задание

# Правила игры


1. Домашние задания **(40 баллов в сумме)**
  - а. Выдаются на 3 и 6 неделях **(20 баллов за каждое)**  $2 \times 20 = 40$  баллов в сумме
2. Тестирования **(20 баллов)**
  - а. Проводятся на 6 и на 11 неделях **(10 баллов за каждое)**  $2 \times 10 = 20$  баллов в сумме
3. Финальное задание **(40 баллов)**
  - а. Выдается на 11 неделе
  - б. Детальная разбалловка фин. задания будет позже

# Применение, историческая справка и текущее состояние МО



Пункт 2/7

# Применение машинного обучения

- Computer vision
- Natural Language Processing
- ...



CAT, DOG, DUCK




# Применение машинного обучения






# Применение машинного обучения



# Применение машинного обучения



**Data**



```
graph LR; A[Data] --> B[Knowledge]
```

The diagram consists of two rounded rectangular boxes with blue borders. The left box contains the word 'Data' and the right box contains the word 'Knowledge'. A blue arrow points from the right side of the 'Data' box to the left side of the 'Knowledge' box, indicating a directional flow from data to knowledge.

**Knowledge**

# ML Словарь

Пункт 3/7

# ML Словарь

## Набор данных (Dataset)

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

## Наблюдение/объект (observation)

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

В большинстве случаев наблюдения должны быть “i.i.d”:

- **independent** (независимы)
- **identically distributed** (одинаково распределены)

# ML Словарь

## Признак (feature)



| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

Это всё признаки



| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |



# ML Словарь

Это всё признаки



| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

Это всё признаки



| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

Это всё признаки



| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

## Матрица плана/признаков (design matrix)

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

# ML Словарь

**Целевая переменная (target)** - информация, которая нас интересует

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

Целевая переменная может быть числом - для задачи **регрессии**

# ML Словарь

**Целевая переменная (target)** - информация, которая нас интересует

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

Или **меткой (label)** для задачи **классификации**

# ML Словарь

Целевая переменная (target) - информация, которая нас интересует

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Target (passed) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|-----------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | TRUE            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | TRUE            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | TRUE            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | TRUE            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | FALSE           |

Оценка также может быть меткой (классами будут числа от 1 до 5)

# ML Словарь

Далее мы будем рассматривать только числовой target (оценку)

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             |



# ML Словарь

Прогноз/предсказание (prediction) содержит значения,

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Predicted (mark) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|------------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | 4.5              |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | 4.5              |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | 5                |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | 3.5              |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | 3                |

Можно заметить, что предсказание - это просто среднее значение оценок за Statistics и Python. Следовательно, нашу **модель** можно представить формулой:

$$\widehat{mark}_{ML} = \frac{1}{2} \cdot mark_{statistics} + \frac{1}{2} \cdot mark_{python}$$

# ML Словарь

**Функция ошибки** (loss function) измеряет частоту ошибок модели.

**Средний квадрат ошибки** (Mean Squared Error)  
( $y$  - это вектор целевой переменной)

$$MSE(y, \hat{y}) = \frac{1}{n} \|y - \hat{y}\|_2^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

| Square deviation | Target (mark) | Predicted (mark) |
|------------------|---------------|------------------|
| 16               | 5             | 1                |
| 1                | 4             | 5                |
| 9                | 5             | 2                |
| 1                | 5             | 4                |
| 1                | 2             | 3                |

# ML Словарь

Для обучения наша модель должна обладать некоторыми степенями свободы:

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Predicted (mark) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|------------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | 4.5              |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | 4.5              |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | 5                |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | 3.5              |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | 3                |

$$\widehat{mark}_{ML} = \frac{1}{2} \cdot mark_{statistics} + \frac{1}{2} \cdot mark_{python}$$

# ML Словарь

Для обучения наша модель должна обладать некоторыми степенями свободы:

| Name         | Age | Statistics (mark) | Python (mark) | Eye color | Native language | Target (mark) | Predicted (mark) |
|--------------|-----|-------------------|---------------|-----------|-----------------|---------------|------------------|
| John         | 22  | 5                 | 4             | Brown     | English         | 5             | 4.447            |
| Aahna        | 17  | 4                 | 5             | Brown     | Hindi           | 4             | 4.734            |
| Emily        | 25  | 5                 | 5             | Blue      | Chinese         | 5             | 5.101            |
| Michael      | 27  | 3                 | 4             | Green     | French          | 5             | 3.714            |
| Some student | 23  | 3                 | 3             | NA        | Esperanto       | 2             | 3.060            |

$$\widehat{mark}_{ML} = w_1 \cdot mark_{statistics} + w_2 \cdot mark_{python}$$

# ML Словарь

Последнее понятие в нашем словаре - это **гиперпараметр** (hyperparameter)

**Гиперпараметры** фиксируются перед началом обучения модели, т.е. до того, как модель начнет обрабатывать данные.

Далее мы ещё обсудим данное понятие, рассматривая kNN.

# ML Словарь

## Резюме:

- Набор данных (Dataset)
- Наблюдение/объект (observation)
- Признак (feature)
- Матрица плана/признаков (design matrix)
- Целевая переменная (target)
- Предсказание/прогноз (prediction)
- Модель (model)
- Функция ошибки (loss function)
- Параметр (parameter)
- Гиперпараметр (hyperparameter)

# Обзор способов машинного обучения

Пункт 4/7


# Обучение с учителем

Введем обозначения:

- Обучающий набор  $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ , где
  - $x^{(i)} \in \mathbb{R}^p, y^{(i)} \in \mathbb{R}$
  - $x^{(i)} \in \mathbb{R}^p, y^{(i)} \in \{C_1, \dots, C_k\}$
- Модель  $f(x)$  предсказывает некоторое значение для каждого объекта
- Функция ошибки  $L(x, y, f)$ , которая должна быть минимизирована




# Задача регрессии (regression)



$$y = w^T + b = \sum_{i=1}^p w_i x_i + b$$

# Задача классификации (classification)




$$y = \text{sign}(\sigma(w^T x + b))$$

# kNN - Метод k ближайших соседей

Пункт 5/7

# kNN - Метод k ближайших соседей



# kNN - Метод k ближайших соседей


Обработка нового объекта:

1. Посчитать дистанции до каждого объекта из набора данных.
2. Выбрать объекты до которых расстояние минимально.
3. Меткой нового объекта будет наиболее частая метка ближайших соседей.

# Как улучшить работу алгоритма?

- Количество соседей  $k$  (это гиперпараметр)

# kNN - Метод k ближайших соседей




# Как улучшить работу алгоритма?

- Количество соседей  $k$  (это гиперпараметр)
- Мера дистанции между объектами
  - Расстояние Хэмминга
  - Расстояние Евклида
  - Косинусное расстояние (cosine distance)
  - Расстояние Минковского
  - и т.д.
- Weighted neighbours




# Weighted (взвешенный) kNN



# Weighted (взвешенный) kNN


k = 4



Веса могут быть подобраны относительно порядку соседей,

$$w(x^{(i)}) = w_i$$

# Weighted (взвешенный) kNN



Веса могут быть подобраны относительно порядку соседей,


$$w(x^{(i)}) = w_i$$

или относительно дистанции

$$w(x^{(i)}) = w(d(x^{(i)}, x))$$

# Weighted (взвешенный) kNN

k = 4



Веса могут быть подобраны относительно порядку соседей,


$$w(x^{(i)}) = w_i$$

или относительно дистанции

$$w(x^{(i)}) = w(d(x^{(i)}, x))$$

$$p_{green} = \frac{w(x^{(1)}) + w(x^{(2)})}{w(x^{(1)}) + w(x^{(2)}) + w(x^{(3)}) + w(x^{(4)})}$$

# Weighted (взвешенный) kNN



Веса могут быть подобраны относительно порядку соседей,

$$w(x^{(i)}) = w_i$$

или относительно дистанции

$$w(x^{(i)}) = w(d(x^{(i)}, x))$$

$$p_{blue} = \frac{w(x^{(3)}) + w(x^{(4)})}{w(x^{(1)}) + w(x^{(2)}) + w(x^{(3)}) + w(x^{(4)})}$$

# Метод максимального правдоподобия Maximum Likelihood Estimation (MLE)

Пункт 6/7

# Функция правдоподобия

Введем датасет, сгенерированный распределением с параметром  $\theta$

Функция максимального правдоподобия **Likelihood** function:

$$\mathcal{L}(\theta|X, Y) = P(X, Y|\theta) = \prod_{i=1}^n P(x^{(i)}, y^{(i)}|\theta)$$

$$\mathcal{L}(\theta|X, Y) \rightarrow \max_{\theta}$$

Объекты должны быть i.i.d.

# Функция правдоподобия

Введем датасет, сгенерированный распределением с параметром  $\theta$

Функция максимального правдоподобия **Likelihood** function:

$$\mathcal{L}(\theta|X, Y) = P(X, Y|\theta) = \prod_{i=1}^n P(x^{(i)}, y^{(i)}|\theta)$$

$$\mathcal{L}(\theta|X, Y) \rightarrow \max_{\theta}$$

Объекты должны быть i.i.d.

Эквивалентно:

$$\log \mathcal{L}(\theta|X, Y) = \sum_{i=1}^n \log P(x^{(i)}, y^{(i)}|\theta) \rightarrow \max_{\theta}$$



# Наивный Байесовский классификатор

Пункт 7/7

# Наивный Байесовский классификатор

Введем обозначение:

- Обучающая выборка  $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ , где
  - $x^{(i)} \in \mathbb{R}^p, y^{(i)} \in \{C_1, \dots, C_k\}$  для К-классовой классификации

# Теорема Байеса

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

или в нашем случае

$$P(y^{(i)} = C_k | x^{(i)}) = \frac{P(x^{(i)} | y^{(i)} = C_k) P(y^{(i)} = C_k)}{P(x^{(i)})}$$

# Наивный Байесовский классификатор

Введем обозначение:

- Обучающая выборка  $\{(x^{(i)}, y^{(i)})\}_{i=1}^n$ , где
  - $x^{(i)} \in \mathbb{R}^p, y^{(i)} \in \{C_1, \dots, C_k\}$  для K-классовой классификации

$$P(y^{(i)} = C_k | x^{(i)}) = \frac{P(x^{(i)} | y^{(i)} = C_k) P(y^{(i)} = C_k)}{P(x^{(i)})}$$

Наивное предположение: все признаки **независимы**

# Наивный Байесовский классификатор

$$P(y^{(i)} = C_k | x^{(i)}) = \frac{P(x^{(i)} | y^{(i)} = C_k) P(y^{(i)} = C_k)}{P(x^{(i)})}$$

Наивное предположение: все признаки **независимы**,  
следовательно:

$$P(x^{(i)} | y^{(i)} = C_k) = \prod_{l=1}^p P(x_l^{(i)} | y^{(i)} = C_k)$$

# Наивный Байесовский классификатор

$$P(y^{(i)} = C_k | x^{(i)}) = \frac{P(x^{(i)} | y^{(i)} = C_k) P(y^{(i)} = C_k)}{P(x^{(i)})}$$

Оптимальная метка класса:

$$C^* = \operatorname{argmax}_k P(y^{(i)} = C_k | x^{(i)})$$

Для подсчета максимума нам не нужен знаменатель  
Но нам он нужен для подсчета вероятностей

# Заключение

1. Важно помнить принцип i.i.d.
2. Даже наивные предположения могут работать в некоторых ситуациях
3. Простые модели предоставляют хорошую основу (**baseline**)

**Спасибо за  
внимание!  
Задавайте вопросы**

