

Машинное обучение

Лекция 2:

Линейные модели

Повторение пройденного материала

- Dataset, наблюдение, признак, матрица плана, целевая переменная
- Свойство i.i.d.
- Модель, предсказание, функция ошибки
- Параметр, гиперпараметр

Содержание

1. Обзор линейных моделей
2. Линейная регрессия под капотом
3. Теорема Гаусса-Маркова
4. Регуляризация в линейной регрессии
5. Валидация и оценка модели

Обзор линейных моделей

Пункт 1/4

Обзор линейных моделей

- Модели регрессии


Предсказанное
значение по оси Y
для наблюдения i

Коэффициент
наклона линии
функции

$$\hat{Y}_i = b_0 + b_1 X_i$$


Свободный член
линейного
уравнения

Значение по оси
X для
наблюдения i




Обзор линейных моделей

- Модели регрессии
- Модели классификации



Обзор линейных моделей

- Модели регрессии
- Модели классификации
- Модели без учителя



Обзор линейных моделей

- Модели регрессии
- Модели классификации
- Модели без учителя
- Блоки из моделей (ансамбли, NN и так далее)

Линейная регрессия

Пункт 2/4

Обучение с учителем

- Датасет $\mathcal{L} = \{x_i, y_i\}_{i=1}^n$, где $(x_i \in \mathbb{R}^p, y_i \in \mathbb{R})$.

Обучение с учителем

- Датасет $\mathcal{L} = \{x_i, y_i\}_{i=1}^n$, где $(x_i \in \mathbb{R}^p, y_i \in \mathbb{R})$.
- Модель линейна:

$$\hat{y} = w_0 + \sum_{k=1}^p x_k \cdot w_k = //x = [1, x_1, x_2, \dots, x_p]// = x^T w$$

Обучение с учителем

- Датасет $\mathcal{L} = \{x_i, y_i\}_{i=1}^n$, где $(x_i \in \mathbb{R}^p, y_i \in \mathbb{R})$.
- Модель линейна:

$$\hat{y} = w_0 + \sum_{k=1}^p x_k \cdot w_k = //x = [1, x_1, x_2, \dots, x_p]// = x^T w$$

где $w = (w_0, w_1, \dots, w_n)$ и w_0 — это смещение (свободный коэффициент)

Мы добавили единичный вектор к матрице значений и таким образом упростили работу со смещением

Обучение с учителем

- Датасет $\mathcal{L} = \{x_i, y_i\}_{i=1}^n$, где $(x_i \in \mathbb{R}^p, y_i \in \mathbb{R})$.

- Модель линейна:

$$\hat{y} = w_0 + \sum_{k=1}^p x_k \cdot w_k = //x = [1, x_1, x_2, \dots, x_p]// = x^T w$$

где $w = (w_0, w_1, \dots, w_n)$ и w_0 – это смещение (свободный коэффициент)

- Метод среднеквадратичной ошибки позволяет получить решение:

$$\hat{w} = \arg \min_w ||Y - \hat{Y}||_2^2 = \arg \min_w ||Y - Xw||_2^2$$

Проблема мультиколлинеарности в обучающих данных

```
w_true
```

```
array([ 2.68647887, -0.52184084, -1.12776533])
```

```
w_star = np.linalg.inv(X.T.dot(X)).dot(X.T).dot(Y)  
w_star
```

```
array([ 2.68027723, -186.0552577, 184.41701118])
```

corresponding features are almost collinear

Проблема мультиколлинеарности в обучающих данных

Общее решение:

$$\begin{aligned}\nabla_w Q(w) &= \nabla_w [Y^T Y - Y^T X w - w^T X^T Y + w^T X^T X w] = \\ &= 0 - X^T Y - X^T Y + (X^T X + X^T X) w = 0\end{aligned}$$

$$\hat{w} = (X^T X)^{-1} X^T Y$$



Вот эта матрица может быть вырожденной!
(Бесконечное количество решений)

Проблема мультиколлинеарности в обучающих данных

Чтобы сделать матрицу невырожденной, мы можем добавить единичную матрицу:

$$\hat{W} = (X^T X + \lambda^2 I)^{-1} X^T Y$$

где $I = \text{diag}[1_1, \dots, 1_p]$

А конечный вариант будет выглядеть так:

$$Q(w) = ||Y - Xw||_2^2 + \lambda^2 ||w||_2^2$$

Функции ошибки

Пункт 3/4

Функции ошибки в регрессии

Среднеквадратичная ошибка:

$$MSE(y, \hat{y}) = \frac{1}{N} \|y - \hat{y}\|_2^2 = \frac{1}{N} \sum_i (y_i - \hat{y}_i)^2$$

Универсальный выбор, дифференцируема

Модуль ошибки:

$$MAE(y, \hat{y}) = \frac{1}{N} \|y - \hat{y}\|_1 = \frac{1}{N} \sum_i |y_i - \hat{y}_i|$$

Используется в случаях, когда нужно увидеть значения ошибки в изначальных величинах

Функции ошибки в регрессии

Мы можем использовать разные нормы как для функции ошибки, так и для регуляризации:

$$MSE = \frac{1}{n} ||\mathbf{x}^T \mathbf{w} - y||_2^2 \quad L_2 : ||\mathbf{w}||_2^2$$

$$MAE = \frac{1}{n} ||\mathbf{x}^T \mathbf{w} - y||_1 \quad L_1 : ||\mathbf{w}||_1$$


В чем разница?

MSE (L2)

- Дифференцируема
- Чувствительна к шуму
- Удовлетворяет условиям теоремы Гаусса-Маркова

MAE (L1)

- Не дифференцируема
- Гораздо менее чувствительна к шуму




В чем разница?

L2-регуляризация

- Дифференцируема
- Позволяет подобрать более стабильное решение

L1-регуляризация

- Не дифференцируема
- Может занулять признаки



Функции ошибки


Существует множество функций для оценки качества регрессии:

- R2 score
- MAPE
- SMAPE
- ...

Валидация и оценка модели


Пункт 4/4

Недообучение vs. переобучение




Under-fitting

(too simple to
explain the
variance)




Appropriate-fitting



Over-fitting

(forcefitting -- too
good to be true)

Недообучение vs. переобучение



Недообучение vs. переобучение

Мы можем контролировать переобучение / недообучение через ёмкость модели:

- Важно уметь правильно выбирать пространство гипотез
- Репрезентативная ёмкость модели может быть больше, чем эффективная ёмкость


Недообучение vs. переобучение

(По-человечески)


Чтобы избегать переобучения или недообучения, мы можем:

1. Выбирать более простые или сложные модели
2. Ограничивать модель во время обучения, не меняя её


Оценка качества



Оценка качества



Оценка качества



Кросс-валидация



В завершение

- Линейные модели просты, но достаточно эффективны
- Регуляризация позволяет ограничивать модель для более качественного обучения
- Вы должны доверять своему процессу валидации